

1 Setup и Задание 1

В задании предлагалось использовать LIBERO и датасет HuggingFaceVLA/libero. В нужном виде сплита `libero_90` в нём не оказалось, поэтому я взял `nvidia/LIBERO-LeRobot_v3:libero_90` как seen-сплит и `libero_goal` как held-out задачи. Для финального сравнения использовались первые три задачи `libero_goal`: открыть средний ящик, положить чашку на плиту, положить бутылку вина на верхнюю часть шкафа.

Сначала дообучил `smolvla_base` на seen-части.




Рис. 1: Seen-success во время pretrain на фиксированном срезе `libero_90`.

Zero-shot success на трёх целевых задачах оказался равен нулю. Это похоже не на полную нечувствительность к тексту, а на слабую композиционную генерализацию: в `libero_90` есть похожие primitives (`open`, `close`, `put/place`, `pick up`), но нет ровно тех же комбинаций object-place-goal. По seen-success лучшими были checkpoint 30000, 70000 и 76000, около 91.7%; для дальнейших запусков я выбрал 70000 как более устойчивую точку в сильном участке 68000–76000.

Далее я сделал naive fine-tuning этого checkpoint отдельно для каждой target-задачи и числа demonstrations 5, 10, 25. Везде использовался одинаковый бюджет 5000 steps, seed 1000, и оценка по 50 episodes. Средний success по трём задачам: 83.3% для 5 demos, 94.7% для 10 demos и 94.0% для 25 demos. Резкий рост от 0 к 5 demonstrations и насыщение около 10 demos подтвердили исходное ожидание: seen-pretrain даёт базовые visuomotor skills, а несколько target demonstrations донастраивают конкретную инструкцию.

2 Задание 2: улучшение cost curve

Во второй части я проверял три способа побить naive baseline: добавить небольшой replay из `libero_90`, изменить частоту replanning через `n_action_steps`, и обучать LoRA-адаптеры вместо обычного fine-tuning. На графике все линии усреднены по трём target-задачам и seed.




Рис. 2: Success rate для задания 1 baseline и трёх методов задания 2.

Replay-эксперимент добавлял 10 seen-эпизодов из `libero_90` к `target demonstrations`. Идея была в том, чтобы сохранить базовые навыки и уменьшить переобучение на маленьких наборах. Результат оказался слабым: 84.7% против 83.3% на 5 demos, затем почти равен baseline на 10 demos и хуже на 25 demos. Значит, простой replay без балансировки помогает только при минимальном target-сигнале, а дальше разбавляет задачу.

Action chunking дал самый полезный результат. В baseline модель исполняет длинный chunk из 50 действий; если она промахнулась в начале, то долго продолжает старый план. При `n_action_steps=10` success стал 92.0%, 92.0%, 97.3% для 5, 10 и 25 demos соответственно. Более агрессивный вариант `n_action_steps=5` я тоже проверял, но он оказался менее устойчивым: небольшая прибавка на 5 demos и ухудшение на 10/25 demos. Поэтому на итоговом графике оставлен лучший и интерпретируемый вариант `n=10`.

LoRA с `r=16`, `alpha=32` не побила baseline: средние значения 80.7%, 81.3%, 78.0%. Она локально улучшила самую слабую точку baseline (task 0, 5 demos), но в среднем ограничение обучаемых параметров оказалось слишком сильным для точной моторной адаптации.

3 Задание 3: разбор фейлов

3.1 Ложный переход к конечной позиции после неудачного захвата

Описание: в задаче с вином робот подходит к бутылке, слегка сдвигает её и закрывает gripper, но стабильного захвата не получается. После этого политика ведёт себя так, будто объект уже в руке: начинает движение к зоне размещения и открывает gripper в воздухе или рядом с целью.

Гипотеза: модель выучила ожидаемую траекторию, но не имеет надёжного сигнала о том что захват успешен.

Альтернатива: проблема ниже уровнем – не в переключении фаз, а в неточном хватании/подходе к перемету.

Разделяющий эксперимент: запустить eval, где бутылка уже находится в gripper и если eval после этого успешен, ломается именно фаза захвата предмета, а если нет – ошибка относится к task-level планированию.

3.2 Движение руки без реального контакта с ручкой

Описание: в задаче с полками gripper выходит в область ящика, но не попадает точно в ручку. После промаха робот всё равно исполняет жест открытия, как будто ручка уже зацеплена.

Гипотеза: политика недостаточно различает состояния «контакт с ручкой достигнут» и «контакт не достигнут».

Альтернатива: политика в принципе знает, что нужен контакт, но визуальная локализация ручки недостаточно точная.

Разделяющий эксперимент: сделать controlled starts с рукой точно на ручке, чуть выше/ниже и чуть левее/правее. Если при точном старте ящик открывается, но при малом смещении recovery нет, проблема в локализации и восстановлении после missed contact; если не работает даже точный старт, плохо выучен сам opening primitive.

3.3 Резкий срыв contact-following после касания

Описание: Это похоже на предыдущий failure, только здесь gripper уже доходит до ручки и недолго касается её, но затем вместо продолжения движения открытия резко уводит руку в сторону.

Гипотеза: модель плохо удерживает направление и давление в контактной фазе.

Альтернатива: касание происходит не той частью gripper или не той частью ручки, поэтому дальнейшее прямое движение действительно становится невалидным.

Разделяющий эксперимент: зафиксировать несколько стартовых состояний с точным выравниванием gripper относительно ручки и отдельно с малым угловым/позиционным смещением. Если с точного старта рука всё равно уходит в сторону, ломается contact-following; если точный старт работает, а смещённые нет, основной источник ошибки – геометрическая точность approach.

4 Задание 4.B: reward-free оценка

Я обучил SARM на libero_90 примерно две эпохи и сравнил его с Robometer-4B-LIBERO. Для каждого бейзлайн ckpt прогонял rollouts на libero_goal. Настоящий success брался из LIBERO env, SARM-score считался как среднее последних 20 reward points в rollout, а Robometer-score – по progress score.

demos	Task 0			Task 1			Task 2		
	GT	SARM	Robo	GT	SARM	Robo	GT	SARM	Robo
0	0.00	0.579	0.326	0.00	0.558	0.383	0.00	0.520	0.392
5	0.70	0.718	0.643	0.95	0.571	0.611	0.85	0.504	0.720
10	1.00	0.718	0.736	0.85	0.532	0.581	1.00	0.557	0.789
25	1.00	0.694	0.735	0.95	0.576	0.607	1.00	0.587	0.788

Таблица 1: gt success и reward-free scores для бейзлайн ckpts.

Главное наблюдение из таблицы: Robometer заметно лучше отражает прогресс checkpoint. На task 0 его score растёт от 0.326 для zero-shot до 0.736 около успешных checkpoint; на task 2 – от 0.392 до 0.789. SARM ведёт себя менее монотонно: например, на task 0 score для 25 demos ниже, чем для 5/10 demos, хотя настоящий success уже равен 1.0. Это ожидаемо, потому что Robometer взят готовым для LIBERO-домена, а SARM я обучал локально и гораздо проще. Прямую оптимизацию политики по SARM/Robometer я не запускал: learned reward может

привести к reward hacking, когда policy максимизирует progress-score вместо выполнения задачи. Более безопасная версия – RA-BC, где progress-score используется только как вес примеров в behavior cloning.

5 Задание 5: summary

Главный результат: zero-shot после seen-pretrain не работает, но 5–10 target demonstrations почти закрывают разрыв. Это значит, что pretrain действительно даёт моторную базу, но не даёт надёжной композиционности по языку. Основная ошибка моей исходной гипотезы была в переоценке переноса seen-primitives: похожие open/put задачи не гарантируют новую комбинацию объекта и цели.

Самым неожиданным оказалось, что изменение inference-time replanning помогло сильнее, чем LoRA. Я ожидал, что выигрыш будет в основном от способа дообучения весов, но failure analysis показывает другое: модель часто почти доходит до правильного контакта, а затем не умеет восстановиться после маленького промаха. `n_action_steps=10` оказался хорошим компромиссом между closed-loop correction и плавностью локального плана.

В «кладбище идей» попали три варианта. Первый – общий replay-датасет для всех target-задач: он портил бы честность cost curve из-за общей нормализации и лишних target episodes. Второй – прямой fine-tuning по learned reward, слишком рискованный из-за reward hacking (его я не запускал). Третий – большой grid search LoRA; после полного прогона стало видно, что выбранная LoRA почти везде проигрывает baseline, поэтому бюджет лучше было вложить в action chunking и анализ rollout failures.